

Series de tiempo ARIMA y SARIMA:

Estudio del comportamiento mensual d la inflación en Argentina desde 1970 a 2024

William Gutierrez

Yza Toro

Michelle Curiel

Paola Puentes

Gabriel Pulido

Elías González

Prof. Laura Castillo

Julio del 2024

Análisis de series de tiempo

El motivo de la introducción de los modelos ARIMA nace del hecho de que no se puede trabajar con una serie temporal no estacionaria. Se dice que una serie es estacionaria cuando su media, varianza y auto covarianza son invariantes en el tiempo. La mayoría de series temporales económicas no son estacionarias, pero diferenciándolas un número determinado de veces la serie original se transforma en estacionaria, con lo cual ya se podría aplicar la metodología de los modelos ARIMA. A continuación, se mostrará la serie de tiempo “**Inflación de argentina**” en la cual se mostrará las sucesiones de datos mensuales desde el año 1970 hasta la actualidad.

MODELO GENERAL ARIMA(p,q,d)

MODELO GENERAL ARIMA(p,q,d)

A continuación, se buscará el modelo que mejor se ajuste a la serie de datos.

Introducción de los datos

```
#library(ggplot2)
##library(forecast)
##library(tseries)
##library(readxl)
##library(lmtest)

##datos <- read_excel("C:/Users/MARK/Desktop/Econometria II/datos de series
de tiempo argentina.xlsx")

##datos.ts= ts(datos)
```


Trazamos la serie de tiempo con ggplot

```
ggplot() +
  geom_line(data = datos, aes(x = Fecha , y = Valor)) + ylab('Inflacion de
argentina')
```

#Usamos medias moviles para suavizar el componente estacional


```
datos$Valor.ma = ma(datos$Valor
, order=7)
datos$Valor30.ma = ma(datos$Valor, order=30)
```

```
ggplot() +
  geom_line(data = datos, aes(x = Fecha, y = Valor, colour = "serie
original")) +
  geom_line(data = datos, aes(x = Fecha, y = Valor.ma, colour = "Weekly
Moving Average")) +
  geom_line(data = datos, aes(x = Fecha, y = Valor30.ma, colour = "Monthly
Moving Average")) +
  ylab('Inflacion de argentina')
```



Primero, calculamos el componente estacional del uso de datos `stl()`. A continuación, hallamos el componente estacional de la serie mediante suavizado y ajusta la serie original restando la estacionalidad.

```
##count_ma = ts(na.omit(datos$Valor30.ma), frequency=30)
##decomp = stl(count_ma, s.window="periodic")
##deseasonal_inf <- seasadj(decomp)
##plot(decomp)
```



```
# Los datos están en la segunda columna:
datos <- datos[[2]]

# Convertir los datos a un objeto de serie de tiempo
datos.ts <- ts(datos, start = c(1970, 7), frequency = 12)

# Verifica la longitud de la serie de tiempo
length(datos.ts)

## [1] 653
```

```
# Descomponer la serie de tiempo
```

```
datos_decomp <- decompose(datos.ts)
```

```
# Dividir la ventana gráfica en una matriz de 2 filas y 2 columnas
```

```
par(mfrow = c(2, 2))
```

```
# Graficar los componentes descompuestos de la serie de tiempo
```


```
plot(datos_decomp$x, main = "Serie de tiempo - Original", col = "black", ylab = "Valores")
```

```
plot(datos_decomp$trend, main = "Tendencia", col = "blue", ylab = "Valores")
```


```
plot(datos_decomp$seasonal, main = "Estacionalidad", col = "red", ylab = "Valores")
```

```
plot(datos_decomp$random, main = "Irregularidad", col = "green", ylab = "Valores")
```


Serie de tiempo - Original




Tendencia



Estacionalidad



Irregularidad



Estacionariedad

La instalación de un modelo ARIMA requiere que la serie sea estacionaria. Se dice que una serie es estacionaria cuando su media, varianza y auto covarianza son invariantes en el tiempo.

Esta suposición tiene un sentido intuitivo:

Dado que ARIMA usa retardos previos de series para modelar su comportamiento

```
adf.test(count_ma, alternative = "stationary")  
  
##  
## Augmented Dickey-Fuller Test  
##  
## data: count_ma  
## Dickey-Fuller = -3.6555, Lag order = 8, p-value = 0.02736  
## alternative hypothesis: stationary
```

Contraste de hipótesis:

H0: No estacionaria **H1:** Estacionaria


Tras realizar la prueba aumentada de Dickey-Fuller (ADF), obtenemos un p-valor = 0.02 Como el p-valor < 0.05, rechazamos H0. Podemos concluir que nuestra serie temporal es estacionaria.

Autocorrelación simple


La función de autocorrelación (ACF) mide la correlación entre una serie de tiempo y sus valores retrasados. **Para determinar el valor de q en un modelo ARIMA**, se puede mirar el gráfico ACF y buscar el primer retraso que tiene una correlación significativa (es decir en donde se sobrepasen las líneas punteadas. *Este valor corresponderá a q (MA=1 O 2 o 3 o...q valor)*

Las PACF proporcionan la relación directa existente entre observaciones separadas por k retardos, **la función de autocorrelación parcial (PACF)** mide la correlación entre una serie de tiempo y sus valores retrasados, pero teniendo en cuenta la influencia de los valores intermedios.

```
Acf(count_ma, main='')
```



```
Pacf(count_ma, main='')
```




Serie de tiempo diferenciadas, es

```
#serie estacionaria
```

```
count_d1 = diff(deseasonal_inf, differences = 1)
```

```
plot(count_d1)
```




```
#decomposicion
```

```
decomp2 = stl(count_d1, s.window="periodic")
```

```
deseasonal_inf2 <- seasadj(decomp2)
```

```
plot(decomp2)
```

Estacionariedad

```
adf.test(count_d1, alternative = "stationary")
```

```
## Warning in adf.test(count_d1, alternative = "stationary"): p-value smaller than
## printed p-value
```

```
##
```

```
## Augmented Dickey-Fuller Test
```

```
##
```

```
## data: count_d1
```

```
## Dickey-Fuller = -4.4557, Lag order = 8, p-value = 0.01
```

```
## alternative hypothesis: stationary
```


Contraste de hipótesis:

H0: No estacionaria **H1:** Estacionaria


Tras realizar la prueba aumentada de Dickey-Fuller (ADF), obtenemos un p-valor = 0.01 Como el p-valor < 0.05, rechazamos H0. Podemos concluir que nuestra serie temporal es estacionaria.

AUTOCORRELACION DE LA SERIE DIFERENCIADA

```
Acf(count_d1, main="")
```



```
Pacf(count_d1, main='')
```



Modelo ARIMA

```
#serie sin diferenciar
auto.arima(deseasonal_inf, seasonal=FALSE)

## Series: deseasonal_inf
## ARIMA(5,1,4)
##
## Coefficients:
##          ar1          ar2          ar3          ar4          ar5          ma1          ma2          ma3
##          0.5751 -0.0991  0.7494 -0.6233  0.2746  1.1146  0.3845 -0.5818
## s.e.  0.0589  0.0455  0.0325  0.0496  0.0451  0.0512  0.0866  0.0843
##          ma4
##          -0.6538
## s.e.  0.0500
##
## sigma^2 = 0.03799: log likelihood = 136.29
## AIC=-252.57 AICc=-252.21 BIC=-208.24

#serie diferenciar
auto.arima(deseasonal_inf2, seasonal=FALSE)

## Series: deseasonal_inf2
## ARIMA(2,0,1) with zero mean
##
## Coefficients:
##          ar1          ar2          ma1
##          0.7528 -0.0679  0.9284
## s.e.  0.0460  0.0459  0.0248
##
## sigma^2 = 0.04205: log likelihood = 102.54
## AIC=-197.08 AICc=-197.01 BIC=-179.35
```

Por lo tanto, basados en los criterios de información, correlogramas y además por parsimonia, elegimos la serie ARIMA (5,1,4).

Validación

```
# Prueba de Ljung-Box
Box.test(datos.ts, lag = 20, type = "Ljung-Box")

##
## Box-Ljung test
##
## data:  datos.ts
## X-squared = 1509.4, df = 20, p-value < 2.2e-16

# Prueba de Shapiro-Wilk
shapiro.test(datos_decomp[random])

##
## Shapiro-Wilk normality test
```

```
##  
## data:  datos_decomp$random  
## W = 0.3872, p-value < 2.2e-16  
  
# Prueba de Shapiro-Wilk  
shapiro.test(datos_decomp$random)  
  
##  
## Shapiro-Wilk normality test  
##  
## data:  datos_decomp$random  
## W = 0.3872, p-value < 2.2e-16
```

Resumen de la Interpretación

- **Error Medio (ME):** Muy cercano a 0, lo cual es positivo y sugiere que el modelo no está sesgado.
- **RMSE y MAE:** Relativamente bajos, lo cual indica que el modelo se ajusta bien a los datos.
- **MPE:** Bajo, indicando un buen rendimiento en términos de error porcentual medio.
- **MAPE:** Alto, sugiriendo posibles problemas con valores atípicos o un ajuste deficiente en ciertas partes de los datos.
- **MASE:** Menor que 1, indicando que el modelo es mejor que un modelo naive.
- **ACF1:** Muy cercano a 0, indicando que no hay autocorrelación significativa en los errores residuales.